Aguirre Rivera Uriel Jefté
Galicia López Alejandro
González Rivera Gerardo Ismael
Rivera Rodríguez Jesús Armando
Equipo: Main
Proyecto IA 1907
Documentación de proyecto: Reconocimiento de múltiples voces (versión final)
Fecha de entrega: 13/11/2026

1. INTRODUCCIÓN

En una clase, una junta de equipo o una reunión, escribir quién dijo qué toma mucho tiempo y casi siempre se pierde información. Las herramientas de transcripción que existen suelen funcionar en la nube, están pensadas para el inglés y, cuando distinguen voces, las nombran como "Hablante 1" o "Hablante 2" sin saber quién es cada persona. Además, cuando dos personas hablan al mismo tiempo, el texto de una de ellas normalmente se pierde.

Este proyecto construye un transcriptor multihablante: un sistema que escucha con un solo micrófono una conversación en español de 2 a 4 personas, reconoce por su voz a las personas que se registraron antes (las "enroladas") y muestra en una aplicación de escritorio, casi en tiempo real, lo que dijo cada quien con su nombre y sus tiempos. Las voces que no están registradas aparecen como "Desconocido 1", "Desconocido 2", etc. Al terminar la grabación, el sistema hace una segunda pasada sobre el audio completo que da una versión final más precisa y, si se elige, separa las partes donde dos personas hablaron al mismo tiempo para recuperar lo que dijo cada una.

Objetivo general. Desarrollar un sistema de inteligencia artificial que identifique a los hablantes de una conversación en español y la transcriba con el nombre de quien habla, usando un solo micrófono y una computadora personal.

Objetivos específicos:

1. Registrar la voz de cada participante con un enrolamiento guiado y con control de calidad.
2. Decidir en cada instante quién está hablando, o si es alguien no registrado.
3. Convertir la voz a texto en español, incluyendo términos técnicos en inglés comunes en Ingeniería en Computación.
4. Separar dos voces que se enciman para no perder lo que dijo cada persona.
5. Mostrar la transcripción en una aplicación de escritorio y entregarla también como archivo de texto.
6. Medir la calidad del sistema con métricas objetivas (porcentaje de error de palabras, porcentaje de palabras atribuidas a la persona correcta y tiempos de cada etapa).

Alcance. El sistema está pensado para conversaciones por turnos, que es lo más común. Cuando dos personas hablan al mismo tiempo, la versión final busca esos momentos y los separa en dos pistas con un modelo de separación de voces (MossFormer2); cada pista se identifica y se transcribe por separado. Separar 3 o más voces simultáneas con un solo micrófono sigue siendo un problema abierto en la investigación actual (Lanzendörfer et al., 2025; Vinnikov et al., 2024), y el modelo que se usa separa solo dos. No se entrenaron redes neuronales desde cero: se integran modelos preentrenados para "escuchar" (detector de voz, huellas de voz, reconocimiento de voz y separación). Aun así, el componente de IA del proyecto es propio y se concentra en la representación del problema como espacio de estados, la combinación de los modelos preentrenados, la búsqueda de la mejor secuencia de hablantes (Viterbi), la calibración de umbrales por persona, las reglas de decisión, la

detección de voces encimadas, el agrupamiento de voces desconocidas y la experimentación y evaluación con datos del equipo.

Versión entregada. Esta documentación corresponde a la versión final del sistema (4.0). Desde la entrega anterior (versión 2.2, 6 de noviembre) se cambió la interfaz completa, se agregó la separación de voces encimadas, los modos de procesamiento, los perfiles de entorno, la detección de frases en inglés, la opción de quitar personas de la plática y el registro de métricas. El sistema se probó en tres computadoras: una PC con tarjeta NVIDIA y dos laptops sin ella. Los cambios se describen en las secciones 4 y 5 y los resultados en la sección 5.6.

2. DEFINICIÓN DEL PROBLEMA

Dominio del problema. Transcripción atribuida por hablante de conversaciones presenciales en español de México, con 2 a 4 participantes que se turnan para hablar y a veces se enciman, grabadas con un solo micrófono (por ejemplo, el de una laptop) en un salón, un cuarto o afuera. Es común que la conversación incluya términos técnicos en inglés ("backend", "deploy", "pull request") y, a veces, frases completas en inglés.

Situaciones iniciales o entradas:

- Audio continuo de un micrófono, en mono, con 16 000 muestras por segundo. Contiene silencios, ruido de fondo, cambios de volumen y, a veces, dos voces al mismo tiempo.
- Galería de voces: por cada persona registrada, su nombre y entre 1.5 y 2 minutos de su voz grabados en 10 tomas cortas con distintos tonos (lectura normal, preguntas, emoción, voz baja, voz fuerte, rápido, lento con números, términos técnicos, una frase en inglés y plática libre).
- Quién está en la plática: antes de grabar se puede quitar a las personas enroladas que no van a participar.
- Entorno y modo: el usuario elige dónde se graba (cuarto silencioso, salón de clase o exterior) y qué hacer al terminar (Rápido, Mejorado o Completo).
- Vocabulario opcional: nombres de los participantes y una lista de términos técnicos que ayudan a que se escriban bien.

Situaciones finales o soluciones aceptables:

- Una lista ordenada de intervenciones con el formato [Nombre] (mm:ss - mm:ss): texto, guardada como archivo .txt.
- Las voces no registradas aparecen como "Desconocido N"; la misma persona desconocida conserva su número durante la sesión.
- Cuando dos voces se enciman y se usa el modo Completo, cada persona conserva su frase y la intervención se marca como encimada.
- Dos versiones: en vivo, que aparece pocos segundos después de que se habla, y final, que se calcula al detener la grabación sobre el audio completo.
- Un registro de métricas de cada grabación (tiempo de cada etapa, voces encimadas encontradas y separadas, tiempo que habló cada persona) en un archivo .csv.

Ejemplo de salida real (versión final, modo Completo, de una prueba en la laptop de Gerardo donde él y otra persona enrolada, Dulce, hablaron al mismo tiempo; sección 5.6):

```
[Dulce] (00:00 - 00:08): Hoy es un buen día para relajarse, disfrutar de las
   pequeñas cosas y no preocuparse tanto por lo que viene mañana. A veces...
   [posible solapamiento con otro hablante]
[Gera] (00:00 - 00:08): A veces uno sale de casa pensando que va a regresar
   rápido, pero termina encontrándose con alguien, haciendo el cliente o
   simplemente... [posible solapamiento con otro hablante]
```

Si solo se transcribe la mezcla, sale únicamente la frase de Dulce; la de Gerardo se recupera gracias a la separación. Si hubiera hablado alguien no registrado, su intervención aparecería como "[Desconocido 1]".

Criterios para aceptar una solución. Se fijaron metas medibles para saber si el sistema cumple:

Criterio	Cómo se mide	Meta
Calidad del texto (versión final)	Porcentaje de error de palabras (WER) contra una transcripción escrita a mano	10 % o menos
Atribución de hablante	Porcentaje de palabras bien transcritas que quedaron con la persona correcta	90 % o más en conversaciones por turnos
Voces encimadas (2 personas)	Palabras recuperadas de cada voz al separar, contra no separar	Recuperar claramente más que sin separar
Retraso en vivo	Tiempo entre que se dice una frase y aparece en pantalla	10 segundos o menos
Personas no registradas	Que aparezcan como "Desconocido" y no con el nombre de otra persona	Mayoría de los casos
Uso práctico	Que funcione en una laptop, sin internet, con un solo micrófono	Sí

Restricciones. Equipo de 4 personas, mes y medio de trabajo, sin entrenar modelos propios (no hay datos ni tiempo para hacerlo bien) y con el equipo de cómputo de los integrantes: una PC con tarjeta NVIDIA y laptops sin ella.

3. ANÁLISIS DEL PROBLEMA

Principales características del problema:

- Es un problema de reconocimiento de patrones con dos partes principales: identificar al hablante (decidir a cuál de las N personas registradas, o a ninguna, pertenece un fragmento de voz) y reconocer la voz (convertir el audio a texto). Se agrega una tercera: separar las voces cuando dos personas hablan al mismo tiempo.
- Las entradas son continuas e inciertas: la misma persona no suena igual al preguntar, al reír o al hablar bajo, y el micrófono capta ruido. Las decisiones se toman con medidas de parecido y umbrales, no con reglas exactas.
- La decisión en un instante depende de los instantes vecinos: la gente habla por turnos de varios segundos, así que no tiene sentido que el hablante cambie cada cuarto de segundo. Esto convierte la identificación en un problema de secuencia: buscar la mejor sucesión de hablantes.
- Hay soluciones intermedias (quién habla en cada ventana de audio, qué palabras se dijeron y en qué segundo, dónde se enciman dos voces) que se combinan para obtener la solución final, de forma parecida a cómo en el ejemplo del sistema experto un síndrome lleva a un diagnóstico.
- El idioma es español con palabras y a veces frases en inglés, lo que obliga a darle al reconocedor de voz conocimiento extra del vocabulario y a detectar cuándo una frase está en inglés.
- El entorno cambia: el ruido, el eco y la distancia al micrófono no son iguales en un cuarto, un salón o afuera, y cada computadora tiene un micrófono y una capacidad de cálculo distinta.

Características clave (según las preguntas de la metodología):

Pregunta	Respuesta para este problema
¿Puede descomponerse en subproblemas independientes (o casi)?	Sí. (a) Detectar dónde hay voz, (b) identificar quién habla, (c) transcribir, (d) buscar y separar voces encimadas y (e) unir las palabras con los hablantes. (b) y (c) trabajan sobre el mismo audio de forma independiente y solo se juntan al final usando los tiempos de cada palabra; (d) solo se hace en la versión final.
¿Pueden ignorarse o deshacerse pasos que no eran adecuados?	Sí, es recuperable. La versión en vivo puede equivocarse; la pasada final vuelve a procesar el audio completo y la reemplaza. Una separación que no convence (las dos pistas suenan a la misma persona) se descarta y se deja el texto como estaba. La grabación se puede descartar y el procesamiento cancelar. En el enrolamiento, una toma mala se repite.
¿Es predecible el universo del problema?	No. Hay ruido, distancia variable al micrófono, personas no registradas, voces encimadas, acentos y palabras en inglés. Por eso se trabaja con similitudes, umbrales, perfiles de entorno y un estado "desconocido", en vez de suponer que todo será como en el enrolamiento.
¿Una solución es buena de forma evidente, sin compararla con todas?	Sí. Se compara contra una transcripción escrita a mano (error de palabras y atribución correcta); basta con que cumpla las metas, no se busca la solución perfecta. Internamente, el algoritmo de Viterbi sí obtiene la mejor secuencia de hablantes, pero sin revisar todas una por una.
La solución, ¿es un estado del mundo o una ruta?	La salida es un estado (el texto final). Por dentro, la identificación de hablantes es una ruta: la secuencia de quién habla en cada cuarto de segundo, y se busca la de mejor puntaje.
¿Se necesita mucho conocimiento o solo para restringir la búsqueda?	Mucho. Conocimiento general (cómo suena el español, qué distingue una voz de otra, cómo se separan dos voces) que aportan modelos preentrenados con miles de horas de audio, y conocimiento particular (las voces del equipo, quién está en la plática, el entorno, el vocabulario técnico, correcciones) que aporta el usuario.
¿La computadora puede dar la solución sola o necesita interactuar con una persona?	Interactúa solo antes y después. Antes, para el enrolamiento guiado, elegir quién está en la plática, el entorno y el modo; después, para revisar o exportar. Durante la conversación el sistema trabaja solo.

Conclusión del análisis. El problema es descomponible, incierto, secuencial y necesita mucho conocimiento previo. Eso apunta a: modelos preentrenados para la parte de percepción, una búsqueda en un espacio de estados para decidir la secuencia de hablantes, y reglas para los casos especiales, incluyendo cuándo vale la pena separar voces.

4. AISLAR Y REPRESENTAR EL CONOCIMIENTO NECESARIO PARA RESOLVER EL PROBLEMA

4.1 Conocimiento sobre la señal: dónde hay voz

Antes de todo, un filtro quita lo que está abajo de 80 Hz (golpes en la mesa, ventilador, vibración), porque la voz no llega tan abajo. Después, un detector de actividad de voz (Silero VAD) da, cada 32 milisegundos, la probabilidad de que haya voz. Con eso el audio se corta en frases: una frase termina cuando hay una pausa o cuando llega a 8 segundos. Las partes sin voz no se transcriben ni se usan para decidir quién habla.

Qué tan seguro debe estar el detector y cuánto dura la pausa depende del entorno que elige el usuario (Tabla 1). En un salón o afuera hay más ruido, así que se pide más seguridad para decir que hay voz, las pausas son más cortas y cambiar de hablante cuesta más.

Entorno	Seguridad del detector	Pausa que cierra una frase	Costo de cambiar de hablante	Ajuste del umbral por ruido
Cuarto silencioso	0.50	600 ms	0.20	0.12
Salón de clase	0.60	500 ms	0.25	0.14
Exterior o ruidoso	0.65	450 ms	0.30	0.16

Tabla 1. Perfiles de entorno. El costo de cambiar de hablante y el ajuste del umbral se usan en la sección 4.3.

4.2 Conocimiento sobre la identidad: huellas de voz

Un modelo de huella de voz (ECAPA-TDNN) convierte 1 o 2 segundos de voz en un vector de 192 números. Dos fragmentos de la misma persona dan vectores parecidos y de personas distintas, vectores diferentes. El parecido se mide con la similitud coseno, que va de −1 a 1:

```
similitud(a, b) = (a · b) / (|a| · |b|)
```

Con esto, el conocimiento de cada persona se representa con estos hechos:

- Huella: el promedio de los vectores de sus ventanas de enrolamiento, descartando el 10 % que menos se parece al resto (toses, golpes, voces de fondo).
- Umbral propio: el punto medio entre sus ventanas propias más bajas (percentil 10) y las ventanas de otras personas que más se le parecen (percentil 90). Una voz muy distinta a las demás necesita menos parecido para reconocerse que dos voces parecidas entre sí (mismo tono y timbre).
- En la plática: si la persona está marcada como presente o no. Si no está, no se considera como opción.

Ejemplo con la galería de las primeras pruebas (similitudes entre huellas y umbral de cada persona):

Persona	Parecido con Isabel	Parecido con Naomi	Parecido con Uriel	Umbral propio
Isabel	1.00	0.57	0.20	0.44
Naomi	0.57	1.00	0.23	0.41
Uriel	0.20	0.23	1.00	0.33

Tabla 2. Las voces de Isabel y Naomi se parecen entre sí (0.57); la de Uriel es muy distinta (0.20-0.23), por eso su umbral es menor.

La aplicación ahora muestra esta tabla en la sección Personas ("Parecido entre voces", Figura 4) y avisa si algún par se parece demasiado. En la laptop de Gerardo, con tres voces nuevas (Dulce, Gera y Román), cada voz se pareció en promedio 0.72 a sus propias tomas y solo 0.12 a las de los demás (0.19 como máximo), y los umbrales quedaron entre 0.28 y 0.33.

Qué tan bien funciona la huella con audio limpio. Con las tomas de enrolamiento de cuatro personas, se identificó cada toma usando solo las demás tomas de cada persona: con pedazos de 1 segundo acertó el 92 % de las veces y con 3 segundos el 98.5 %. En una plática real el parecido baja (entre 0.2 y 0.5 contra la huella propia) por risas, distancia al micrófono o voces encimadas, y la mayoría de los errores eran personas que ni siquiera estaban en la grabación. Por eso se agregó la opción de quitar de la plática a quien no va a hablar (Figura 6): una persona menos es un estado menos en la búsqueda y una forma menos de equivocarse.

4.3 Representación del problema de "quién habla" como espacio de estados

El audio de cada frase se divide en tramos de 0.25 segundos y se analizan ventanas de 1 segundo que se traslapan. El problema se representa así:

- Estados: una persona registrada que está en la plática (P1, P2, …, PN) o "Desconocido".
- Puntaje de un estado en un tramo: parecido promedio de las ventanas con la huella de esa persona menos su nivel de aceptación (umbral propio − ajuste del entorno, Tabla 1). El estado "Desconocido" vale 0. Los tramos sin voz no aportan evidencia.
- Costo de transición: cambiar de hablante cuesta entre 0.20 y 0.30 puntos según el entorno; seguir con el mismo no cuesta nada.
- Solución buscada: la ruta de estados (uno por tramo) con el mayor puntaje total, es decir, la suma de los puntajes menos los costos de cambio.

4.4 Conocimiento sobre el idioma

El reconocimiento de voz usa Whisper, un modelo preentrenado con 680 000 horas de audio en muchos idiomas. Se le agrega conocimiento del dominio de tres formas: un texto de contexto ("Conversación en español de México entre estudiantes de Ingeniería en Computación, con términos técnicos en inglés…"), una lista de palabras clave (los nombres de los participantes y los términos técnicos) y una tabla de correcciones del tipo "pul request = pull request".

En la versión final se agregó conocimiento para tres problemas que aparecieron en las pruebas:

- Frases completas en inglés. Antes se traducían al español. Ahora, en cada frase de 2 segundos o más, se compara qué tan probable es que sea inglés contra español; si es inglés con 85 % de seguridad o más, se transcribe en inglés. Opcionalmente, las palabras en inglés que no son vocabulario técnico se pueden traducir al español con un modelo de traducción (Marian opus-mt-en-es).
- Frases inventadas. En silencios, Whisper a veces escribe frases que nadie dijo ("gracias por ver el video", "suscríbete") o se cicla repitiendo lo mismo. Se tiene una lista de esas frases típicas y se quitan.
- Frases saltadas. Si en la versión final queda un hueco de 1.2 segundos o más sin palabras donde el detector sí oyó voz, ese pedazo se vuelve a transcribir.

4.5 Conocimiento sobre las voces encimadas

Cuando dos personas hablan a la vez, la huella de esa ventana es una mezcla: se parece un poco a las dos en vez de mucho a una sola. Ese es el indicio que se usa para encontrar las partes encimadas. Un modelo de separación (MossFormer2) recibe el pedazo mezclado, de hasta 9 segundos, y regresa dos pistas, cada una con una sola voz y con el mismo volumen que el audio original. Después, cada pista se identifica con su huella y se transcribe por separado. El separador siempre regresa dos pistas, aunque en el audio haya hablado solo una persona o hayan hablado tres; por eso, antes de aceptar el resultado se revisa que de verdad sean dos personas distintas (reglas de la sección 4.6).

4.6 Representación del conocimiento con hechos y reglas

Las decisiones que no resuelven los modelos se representan con reglas del tipo SI… ENTONCES. Se separan en dos grupos: las reglas de conocimiento del dominio, que describen cómo es una conversación (quién habla, voces desconocidas, voces encimadas, idioma y turnos), y las reglas de control y corrección, que cuidan la calidad de los datos y corrigen errores propios del sistema.

Reglas de conocimiento del dominio:

```
SI  la persona P no está en la plática
ENTONCES P no es un estado posible
```

```
SI  puntaje(P) es el mayor   Y   puntaje(P) > 0
ENTONCES hablante = P

SI  ninguna persona supera su nivel de aceptación
ENTONCES hablante = Desconocido

SI  hablante = Desconocido   Y   parecido(tramo, grupo Dk) >= 0.30
ENTONCES etiqueta = "Desconocido k"
SI NO, SI el tramo dura 1.5 s o más
ENTONCES crear el grupo "Desconocido k+1"

SI  dos personas superan su nivel   Y   su diferencia < 0.05   durante 1 s o más
ENTONCES marcar "posible solapamiento con otro hablante"

SI  en una ventana con voz la segunda persona más parecida también supera su nivel
    Y   pasa en al menos la mitad de las ventanas vecinas   Y   dura 1 s o más
ENTONCES es un candidato a voces encimadas (se manda al separador en modo Completo)

SI  una frase dura 2 s o más   Y   es inglés con 85 % de seguridad o más
ENTONCES transcribirla en inglés

SI  un fragmento tiene 1 o 2 palabras   Y   no termina en punto
    Y   la palabra siguiente va en minúscula   Y   la pausa es menor a 0.3 s
ENTONCES el fragmento pertenece al hablante vecino
```

Reglas de control y corrección:

```
SI  una ventana tiene voz en menos de la mitad de su duración
ENTONCES no aporta evidencia (sigue quien venía hablando)

SI  las dos pistas separadas se parecen entre sí más de 0.35
    O   una pista tiene menos de 1 s de voz   O   menos de 3 palabras
    O   una pista suena menos del 5 % que la otra
    O   las dos pistas salen con el mismo dueño
ENTONCES rechazar la separación y dejar el texto como estaba

SI  hay un hueco de 1.2 s o más sin palabras   Y   el detector oyó 0.8 s de voz o más
ENTONCES volver a transcribir ese hueco

SI  el texto es una frase típica inventada ("gracias por ver", "suscríbete"...)
ENTONCES quitarla

SI  un grupo de palabras se repite 3 veces o más seguidas
ENTONCES dejar solo la primera (bucle del reconocedor)

SI  el texto contiene un término de la tabla de correcciones
ENTONCES reemplazarlo por su forma correcta
```

También son de control las reglas del enrolamiento, que aseguran la calidad de la galería:

```
SI  la toma tiene pocos segundos de voz   O   volumen muy bajo
    O   está saturada (más del 0.1 % de las muestras en el tope)
ENTONCES poner el medidor en rojo y pedir repetir la toma

SI  parecido(toma, demás tomas de la persona) < 0.45
ENTONCES descartar la toma (probablemente habló otra persona o hubo ruido)
```

```
SI  parecido(persona nueva, persona ya registrada) >= 0.75
ENTONCES avisar: posiblemente es la misma persona con otro nombre
```

5. ELEGIR LA(S) MEJOR(ES) TÉCNICA(S) QUE RESUELVA(N) EL PROBLEMA

5.1 Técnicas elegidas

Subproblema	Técnica	Por qué
Detectar voz	Red neuronal preentrenada Silero VAD, con filtro de graves antes	Ligera, corre en el procesador y no depende del volumen de cada persona.
Huella de voz	Red ECAPA-TDNN preentrenada con VoxCeleb (SpeechBrain)	Es de las mejores en verificación de hablante y se usa sin entrenar.
Decidir quién habla	Búsqueda del mejor camino con el algoritmo de Viterbi (programación dinámica) sobre el espacio de estados de la sección 4.3	Encuentra la mejor secuencia de hablantes sin revisar todas las posibles y evita cambios absurdos de hablante cada cuarto de segundo.
Personas no registradas	Agrupamiento incremental por parecido	Da un número estable a cada voz desconocida sin saber cuántas habrá.
Voz a texto	Whisper (faster-whisper): modelo small en vivo y large-v3-turbo en la versión final, con búsqueda en haz de 5 hipótesis	Modelo abierto con buen desempeño en español. El chico da texto rápido en vivo; el grande da la versión final más precisa, también en computadoras sin NVIDIA.
Voces encimadas	Red preentrenada MossFormer2 (separación de 2 voces a 16 kHz, de ClearerVoice-Studio)	En las pruebas recuperó más palabras que SepFormer (sección 5.3) y se puede usar sin entrenar.
Frases en inglés	Detección de idioma de Whisper, comparando solo inglés contra español	Ya viene en el modelo; comparar solo esos dos idiomas evita confundir español con otros.
Traducción opcional	Modelo Marian opus-mt-en-es (OPUS-MT) en CTranslate2	Pequeño, corre en el procesador y solo se usa si el usuario lo activa.
Casos especiales	Reglas SI… ENTONCES (encadenamiento hacia adelante)	Son pocas, claras y fáciles de ajustar.

5.2 Por qué Viterbi: la búsqueda del mejor camino

Si una frase de 20 segundos tiene 80 tramos y hay 4 estados posibles (3 personas y "Desconocido"), existen 4^80 secuencias distintas, un número imposible de revisar una por una. El algoritmo de Viterbi resuelve la búsqueda con programación dinámica: para cada tramo t y cada estado k guarda el mejor puntaje acumulado de llegar ahí,

```
V(t, k) = E(t, k) + máx sobre j de [ V(t-1, j) - c · (j ≠ k) ]
```

donde c es el costo de cambiar de hablante (0.20 en un cuarto silencioso), y al final recorre hacia atrás las decisiones guardadas. Así hace 80 × 4 × 4 = 1 280 operaciones en vez de 4^80 y garantiza el camino óptimo. Es una búsqueda en un espacio de estados, como las vistas en la unidad de problemas y búsqueda, del tipo no informada (no usa heurística, sino el costo exacto acumulado, como la búsqueda de costo uniforme) y resuelta con programación dinámica. Quitar de la plática a quien no va a hablar reduce los estados: con 3 personas en vez de 4 son 4 × 4 en lugar de 5 × 5 comparaciones por tramo.

Relación con las búsquedas vistas en clase. El espacio de estados de la sección 4.3 es un grafo por niveles (un nivel por tramo de audio, un nodo por persona). Sobre ese grafo:

Búsqueda de clase	Qué pasaría en este problema
Profundidad	Recorrer cada camino completo uno por uno: 4^80 caminos en una frase de 20 s. Imposible.
Anchura	Viterbi avanza igual, nivel por nivel, pero en cada nodo solo conserva el mejor camino que llega a él (principio de optimalidad de Bellman).
Escalada simple / máxima pendiente	Elegir en cada tramo el mejor paso inmediato sin regresar. Es rápido, pero cae en óptimos locales: un ruido de un tramo cambia de hablante.
Primero mejor	También expande lo más prometedor, pero necesita una heurística; Viterbi usa el costo exacto acumulado y garantiza el mejor camino.

La Figura 1 compara escalada y Viterbi con datos reales: un fragmento de 7.5 segundos de una de las conversaciones de prueba (minuto 0:58 a 1:05.5) en el que Uriel habla, Alejandro lo interrumpe y Uriel retoma. Cada número es el puntaje real que dio la huella de voz en ese tramo. La escalada se equivoca en 2 de 13 tramos: empieza como "Desconocido" porque el primer tramo es débil y tarda un tramo en regresar a Uriel. Viterbi, que compara caminos completos, acierta los 13. En toda esa conversación (256 tramos con voz), la escalada se equivocó en 4.7 % de los tramos y Viterbi en 0.8 % (Figura 12).

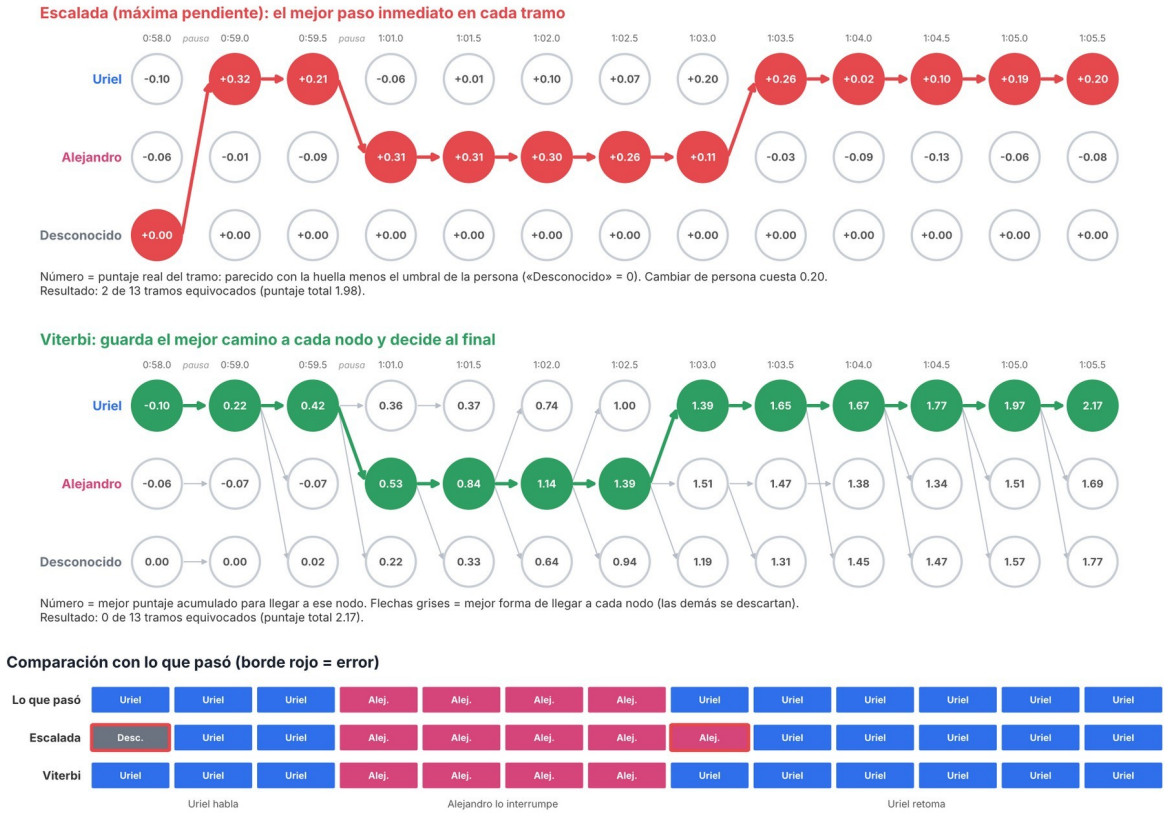


Figura 1. Escalada contra Viterbi en el grafo de hablantes con puntajes reales de una conversación de prueba (tramos de medio segundo para que la figura se lea mejor).

5.3 Técnicas que se probaron y se descartaron

Técnica	Por qué se descartó
Diarización a ciegas con pyannote.audio	Por diseño modela como máximo 2 hablantes a la vez, pide un token de Hugging Face y tuvo conflictos de versiones en Colab.
Entrenar un modelo propio	No hay datos suficientes en español ni tiempo para entrenarlo bien.
Un solo umbral para todas las personas	Dos voces parecidas lo subían para todos; con una sola persona hablando, partes de sus frases salían como "Desconocido" (Figura 11).
Que Whisper arrastre el texto anterior entre ventanas	Provocó bucles de frases repetidas: el error subió de 10.3 % a 24.9 %.
Penalizar repeticiones en Whisper	Empeoró el error a 33.1 %.
Dar a Whisper audio anterior como contexto en vivo	Resultados inconsistentes (de 15.3 % a 20.1 % de error según la variante) y hasta 30 % más lento; alargar las frases a 8 s dio 14.6 % sin costo extra.
Separar voces con SepFormer	En 10 mezclas armadas recuperó 48 % de las palabras contra 69 % de MossFormer2, y en una grabación real las dos pistas sonaban a la misma persona.
Separar voces en vivo	Separar es lo más tardado del sistema (varios segundos por cada segundo de voz sin tarjeta NVIDIA); solo se hace en la versión final y solo en las partes encimadas, con un tope del 30 % del audio.
Quitar el ruido con un modelo de limpieza de audio	Un estudio con Whisper y otros tres reconocedores encontró que el audio limpiado se transcribe peor en las 40 configuraciones probadas (Chondhekar et al., 2025). Se dejó solo el filtro de graves, que es barato y no deforma la voz.

5.4 Implementación

El sistema está escrito en Python 3.11 y tiene unas 5 450 líneas en sus cuatro archivos principales. La Figura 2, después de la tabla, muestra el flujo completo.

Componentes principales del código (repositorio github.com/UJefte/transcriptor-multihablante):

Archivo o carpeta	Qué hace
transcriptor.py (1 563 líneas)	El modelo: filtro de graves, detector de voz, huellas, galería y umbrales, Viterbi, transcripción por bloques, frases en inglés, reglas, búsqueda y separación de voces encimadas, pasada final. También funciona por consola.
motor.py (1 116 líneas)	Une la interfaz con el modelo: enrolamiento con revisión de calidad, perfiles de entorno, conversación en vivo, modos al terminar, cancelar y descartar, métricas en CSV y prueba de micrófono.
app.py (2 682 líneas)	Aplicación de escritorio hecha con CustomTkinter: Conversación, Separar voces, Personas, Ajustes y Enrolar. Los íconos y círculos se dibujan con Pillow.
separador.py (93 líneas) y mossformer2_ss/	Carga MossFormer2 y separa un pedazo de audio en dos pistas con el mismo volumen que el original. La carpeta tiene el código de la red, tomado de ClearerVoice-Studio (licencia Apache-2.0).
traductor.py	Traducción opcional del inglés que no es vocabulario técnico (Marian opus-mt-en-es).
diagnostico.py	Datos del equipo (procesador, tarjeta, versiones) y paquete de pruebas sin voces para revisar errores.

Archivo o carpeta	Qué hace
herramientas/	Descargar el separador, preparar el traductor y probar el micrófono.
evaluacion/	evaluar.py (error de palabras y atribución contra una transcripción escrita a mano) y experimento_espanglish.py (comparar configuraciones del reconocedor).
construir_exe.bat, transcriptor.spec	Generan el ejecutable de Windows (PyInstaller).

Para que la ventana no se congele, todo lo que tarda (cargar modelos, transcribir, separar) se corre en otro hilo, y los resultados regresan a la interfaz por una cola que se revisa cada pocos milisegundos. Los modelos dejan un núcleo del procesador libre para la ventana.

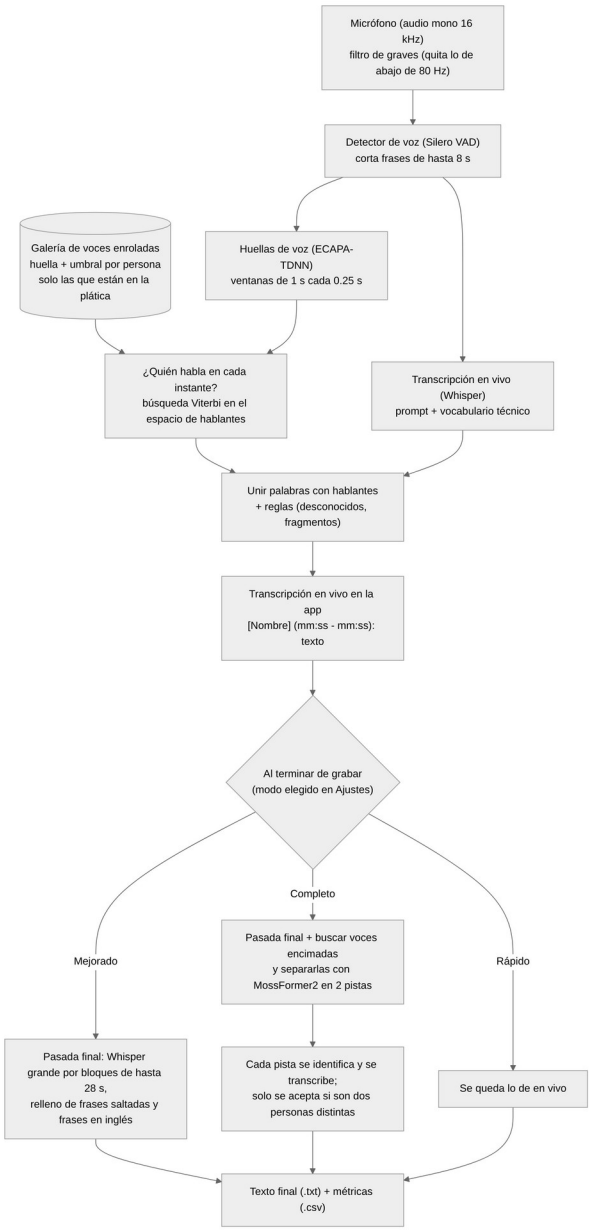


Figura 2. Flujo del sistema: del micrófono a la transcripción en la aplicación, con los tres modos al terminar de grabar.

5.5 La aplicación

La interfaz se rehízo por completo con CustomTkinter. Las capturas de esta sección se tomaron de las grabaciones del video del proyecto, en la PC con tarjeta NVIDIA.

Enrolar. Cada persona lee 10 frases con distintos tonos; cada una incluye todos los sonidos del español. La aplicación revisa cada toma al momento: si la voz está saturada, las barras del medidor se ponen rojas y pide repetirla. Al final muestra la revisión de las 10 tomas, marca en rojo las que hay que repetir y dice cuál es la voz enrolada más parecida (Figura 3).

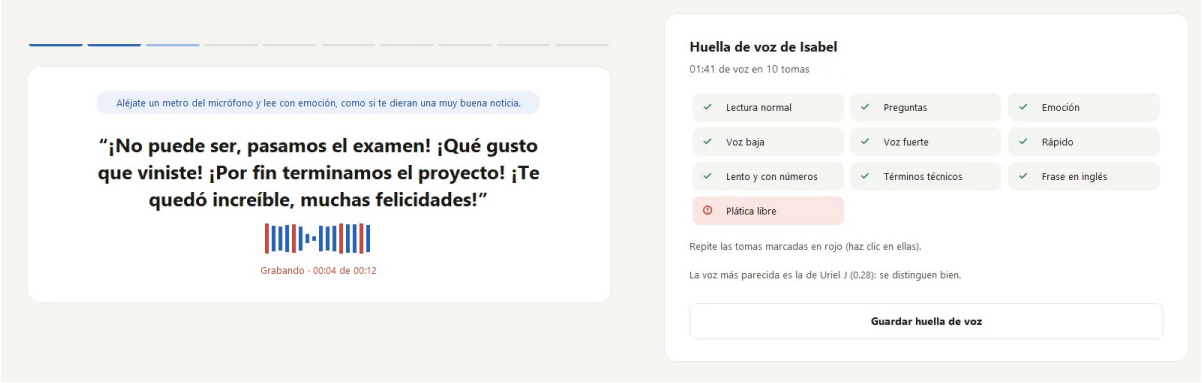


Figura 3. Enrolamiento: toma 3 de 10 (emoción) con barras rojas por saturación, y revisión final de la huella con la toma de plática libre marcada para repetir.

Personas. Muestra a cada persona enrolada con su interruptor de "En la plática", la tabla de parecido entre voces, las métricas por persona y el botón "Probar voz", que graba unos segundos y dice a quién se parece la voz y con qué puntaje (Figura 4).

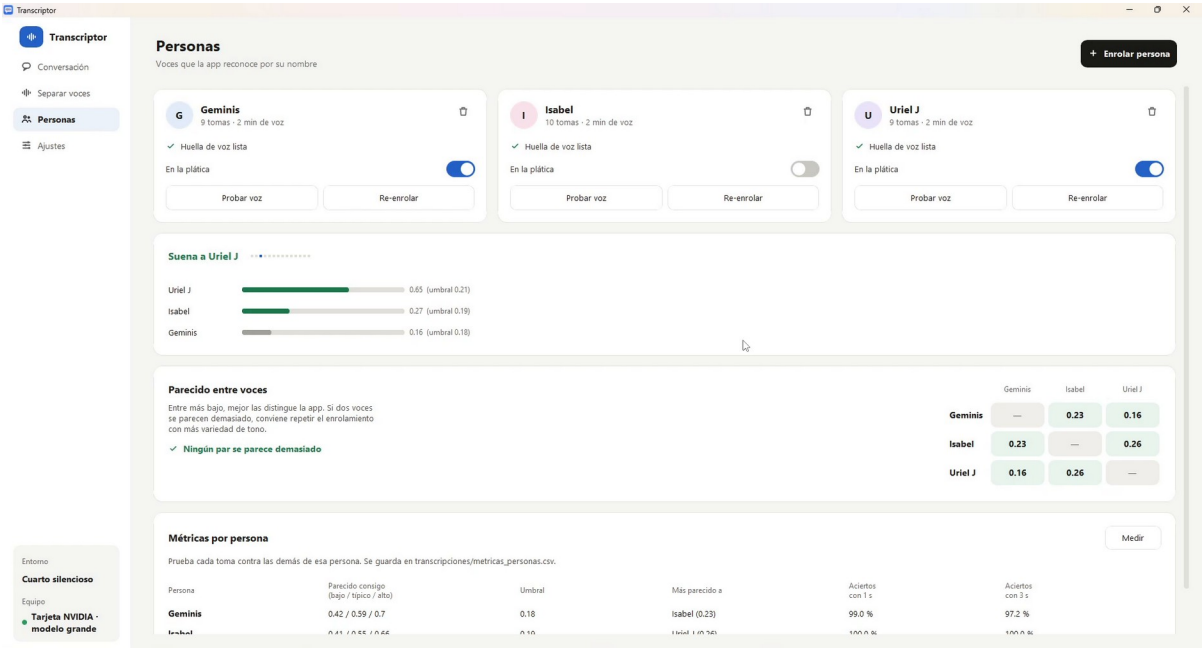


Figura 4. Personas: "Probar voz" reconoció a Uriel J (0.65 contra su umbral de 0.21), tabla de parecido entre voces y métricas por persona.

Conversación. Al grabar, la transcripción aparece en vivo con el nombre y el color de cada quien (Figura 5). Mientras graba se puede descartar la grabación.

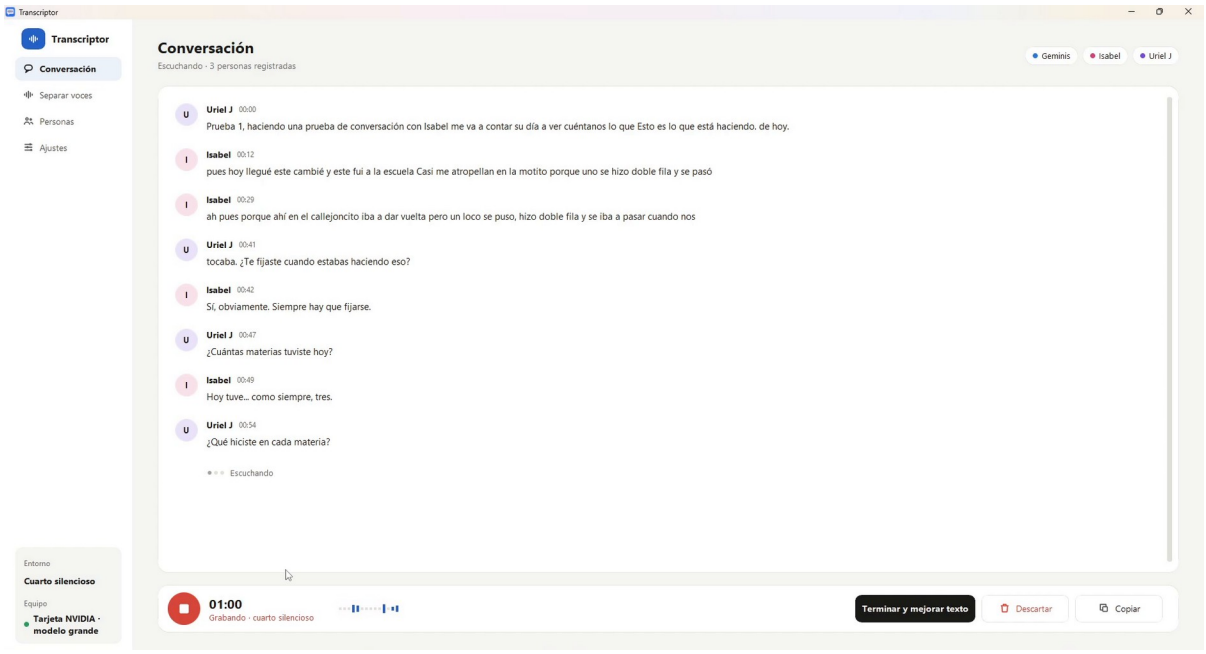


Figura 5. Conversación en vivo: cada frase aparece con el nombre de quien habló y su tiempo.

Arriba se tocan los nombres para quitar a quien no está en la plática (Figura 6).

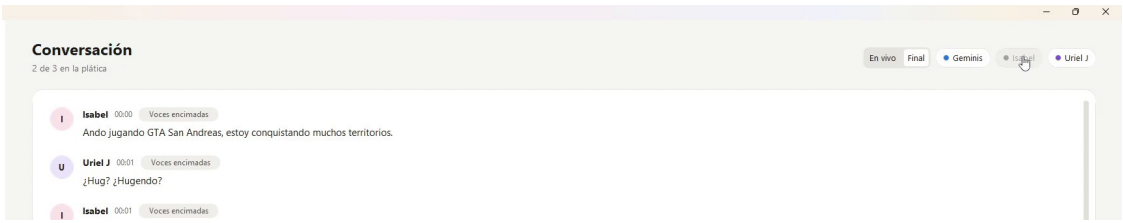


Figura 6. Isabel quitada de la plática: su nombre aparece en gris y el subtítulo dice "2 de 3 en la plática".

Al terminar, se hace la versión final según el modo elegido. Una barra muestra la etapa y el tiempo aproximado, y se puede cancelar (Figura 7). En modo Completo, las frases que se separaron quedan marcadas como "Voces encimadas" (Figura 8). La versión final se guarda sola como archivo de texto.

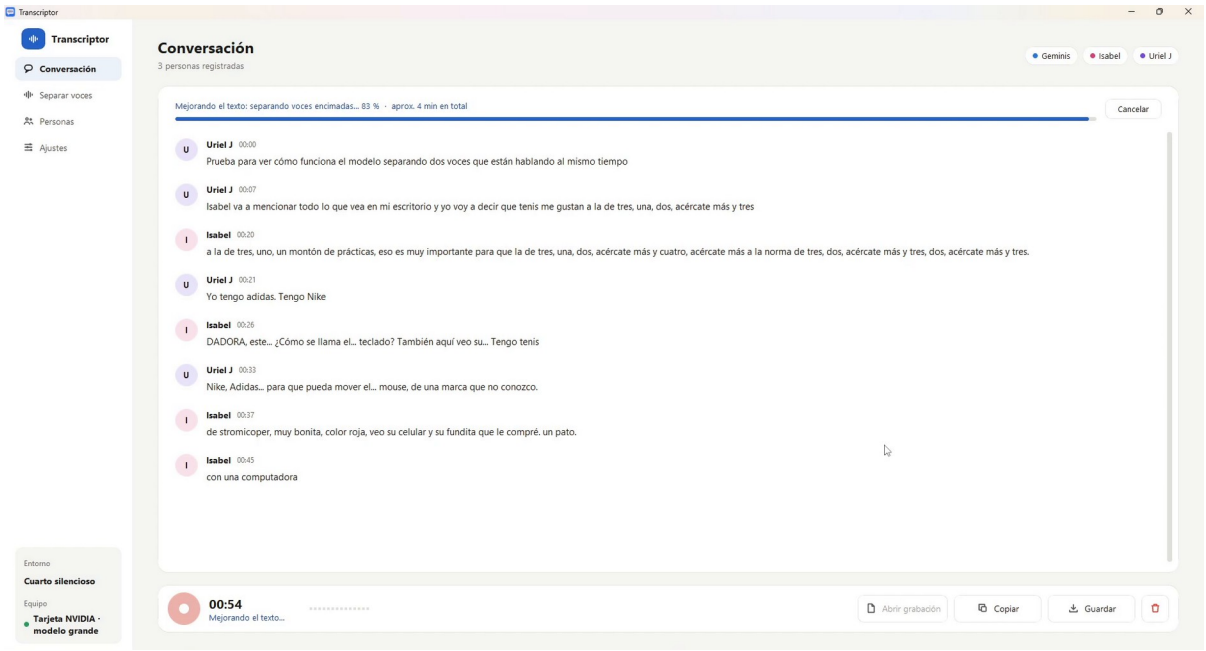


Figura 7. Versión final en proceso: separando voces encimadas, con botón "Cancelar".

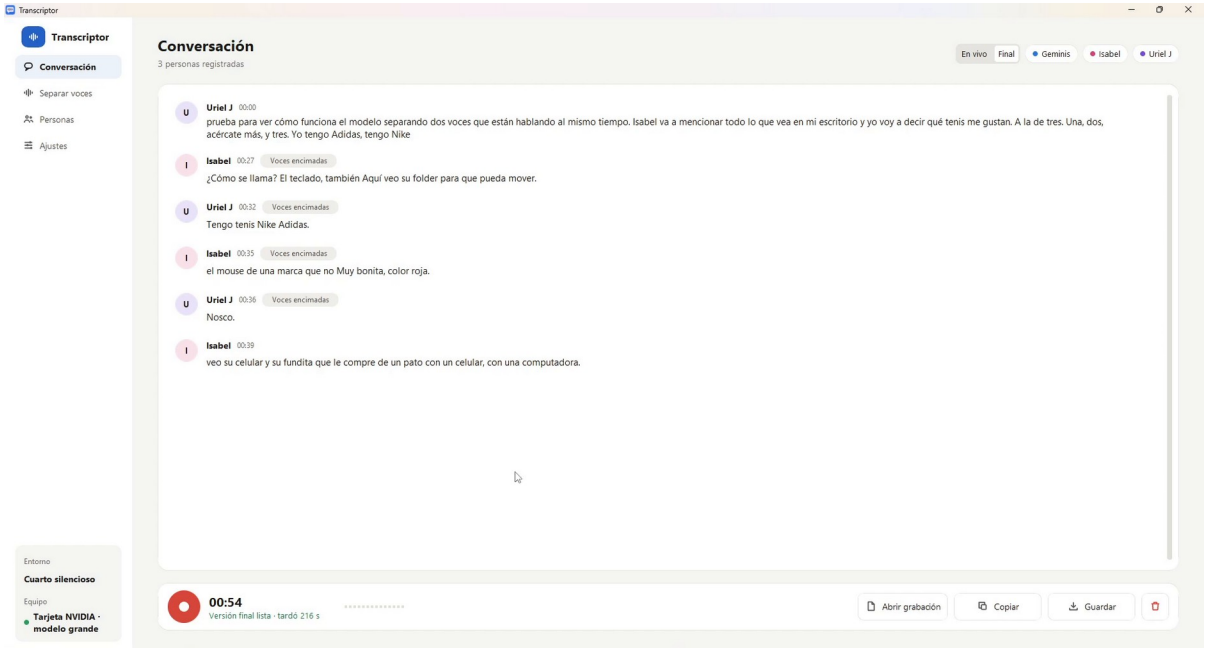


Figura 8. Versión final de una plática donde Isabel y Uriel hablaron al mismo tiempo: las frases separadas llevan la etiqueta "Voces encimadas".

Ajustes. Aquí se elige el entorno (cuarto silencioso, salón de clase o exterior) y qué hacer al terminar de grabar: Rápido se queda con lo que salió en vivo, Mejorado vuelve a transcribir todo con el modelo grande y Completo además separa las voces encimadas (Figura 9). La aplicación mide en cada computadora cuánto tarda y muestra el tiempo estimado de cada modo. También están la traducción opcional, el equipo que se usa para transcribir, la prueba de micrófono y el paquete de pruebas.

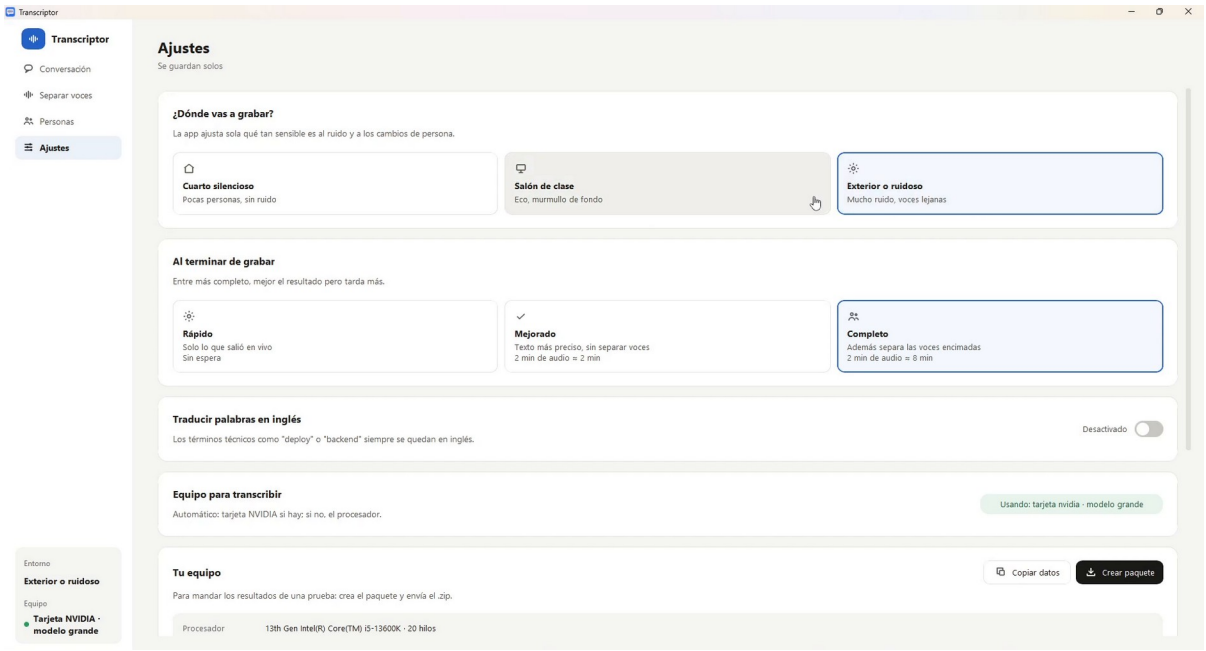


Figura 9. Ajustes: perfiles de entorno y modos al terminar de grabar, con su tiempo estimado.

Separar voces. Esta pestaña no es para el uso diario: se hizo para mostrar paso a paso lo que la versión final hace en las partes encimadas. Abre un audio de hasta 9.5 segundos, muestra lo que escribe Whisper sin separar y luego las dos pistas, cada una con su dueño, su parecido y su texto (Figura 10).

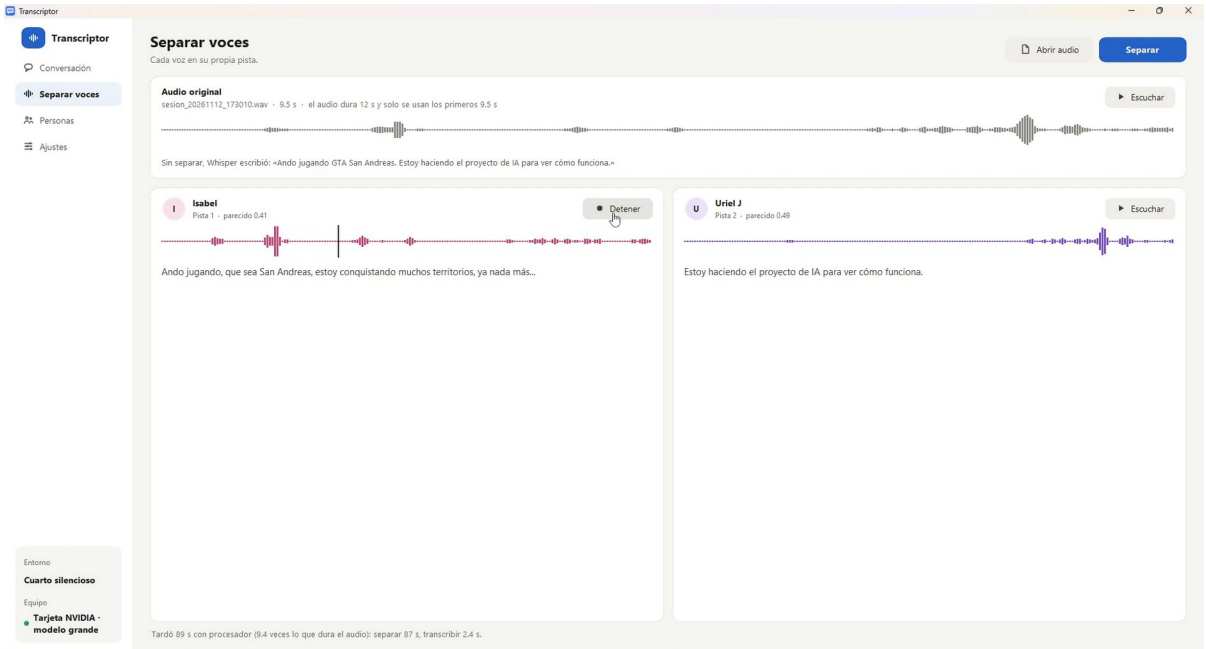


Figura 10. Separar voces: sin separar, Whisper juntó las dos frases como si fueran de una persona; separando, cada pista sale con su dueño y su texto.

5.6 Resultados obtenidos

Identificación de hablante: primer modelo contra el segundo. El modelo 1 (primera versión) decide quién habla en cada ventana por separado y usa un solo umbral para todas las personas. El modelo 2 busca la mejor secuencia de hablantes con Viterbi y usa un umbral propio para cada persona; es el

que se conserva en la versión final. Para compararlos en igualdad de condiciones, los dos se corrieron con el mismo código y los mismos audios; solo cambian esas dos piezas. La primera medición, con conversaciones armadas con voz real de 2 y 3 personas, ya había pasado de 84.6 % (modelo 1) a 97.4 % (modelo 2) de tiempo bien atribuido. La Figura 11 muestra el resto de las pruebas:

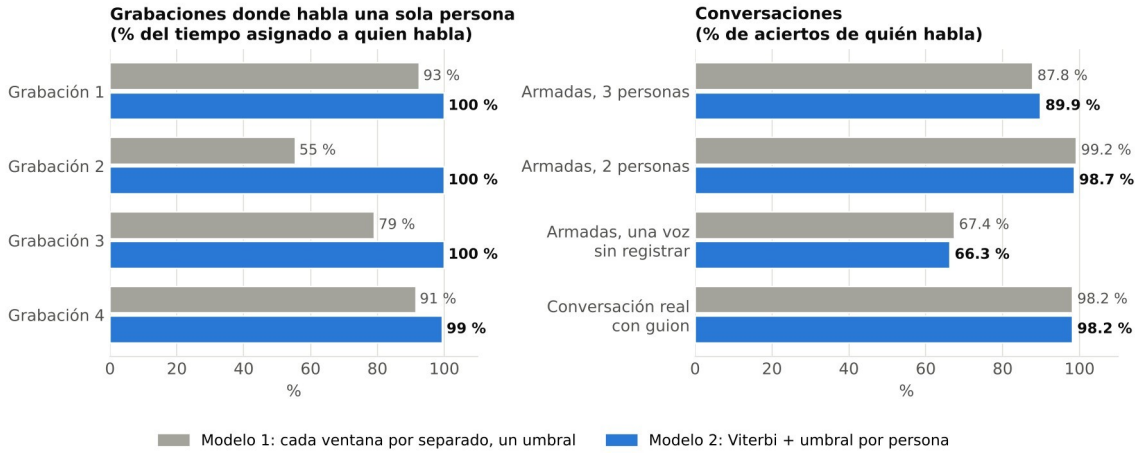


Figura 11. Atribución de hablante del modelo 1 contra el modelo 2. Las conversaciones armadas usan audio que no se usó en el enrolamiento; en la de "una voz sin registrar" lo correcto es que salga "Desconocido".

Las mayores diferencias están en las grabaciones de una sola persona (de 55 %–93 % a 99 %–100 %): con un solo umbral, partes de sus frases salían como "Desconocido". En la conversación real con guion ambos modelos atribuyen igual las palabras (98.2 %), pero la Figura 12 muestra la diferencia tramo por tramo: el modelo 1 cambia de persona 54 veces cuando en realidad hubo 13 cambios, lo que en la aplicación se ve como intervenciones partidas en pedazos. Con Viterbi quedan 19 cambios y solo 0.8 % de tramos equivocados.

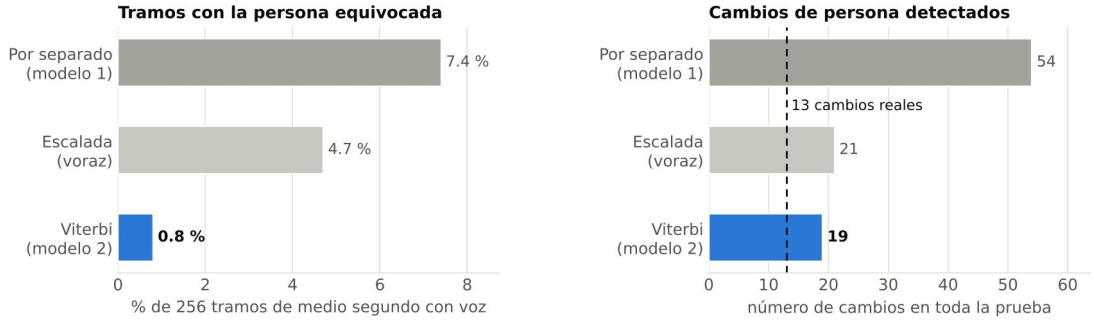


Figura 12. Conversación real con guion, analizada en tramos de medio segundo: el modelo 1, la escalada y Viterbi (modelo 2).

En el caso de una voz no registrada parecida a una registrada, ninguno de los dos modelos mejora (alrededor de 67 %): Viterbi ayuda a no saltar entre personas, pero no puede distinguir dos voces cuyas huellas se parecen mucho.

Transcripción. Lectura de 438 palabras con 60 términos técnicos en inglés (204 segundos, una persona):

Configuración	Error de palabras	Términos técnicos bien escritos
Versión final, modelo grande en tarjeta NVIDIA, sin ayuda de vocabulario	10.3 %	83 %

Configuración	Error de palabras	Términos técnicos bien escritos
Versión final, modelo grande, vocabulario técnico + bloques cortados en pausas (actual)	8.7 %	89 %
En vivo, modelo chico en procesador, frases de 6 s	16.7 %	—
En vivo, modelo chico en procesador, frases de 8 s (actual)	14.6 %	—

Tabla 3. Error de palabras (WER): sustituciones + palabras borradas + palabras inventadas, entre el total de palabras de la referencia.

Frases completas en inglés. Con la detección de idioma, las frases en inglés de las pruebas ahora se escriben en inglés en vez de traducirse. En cuatro grabaciones que solo tenían español el resultado salió idéntico al de antes, es decir, la detección no cambió nada que no debía.

Voces encimadas. Se armaron 10 mezclas de Isabel y Uriel hablando al mismo tiempo, con frases conocidas, y se midió qué porcentaje de las palabras de cada voz se recuperaba:

Método	Palabras recuperadas de cada voz	Pistas con el dueño correcto
Sin separar (transcribir la mezcla)	32 %	—
SepFormer	48 %	10 de 10
MossFormer2 (elegido)	69 %	10 de 10

Tabla 4. Separar más que duplica las palabras que se recuperan cuando dos personas hablan a la vez.

En la plática normal de una de las pruebas hubo 5 momentos que parecían encimados, pero no se separó ninguno, porque el separador comprueba que las dos pistas sean de personas distintas antes de aceptar. En la demostración del video (Figura 10), sin separar Whisper juntó las dos frases como si fueran de una sola persona; separando, cada una salió completa con su dueño.

Pruebas en otra computadora. Gerardo probó la versión final en su laptop (Intel Core Ultra 5, sin tarjeta NVIDIA) con tres voces que no se habían usado antes: la suya, la de Dulce y la de Román. Ahí el sistema usa el modelo chico en vivo y el grande en la versión final, todo en el procesador.

Medida (audio de unos 15 s, modo Completo)	Prueba 1: dos voces a la vez	Prueba 2: tres voces a la vez
Partes encimadas encontradas / separadas	2 / 2	3 / 1
Resultado	Las dos frases completas, cada una con su dueño	28 % del audio como "Desconocido"
Quién habla + transcribir (lo que tarda Mejorado)	34 s	34 s
Separar voces	4 min 17 s	4 min 40 s
Tiempo total contra lo que dura el audio	19 veces	20 veces
Retraso en vivo (promedio / máximo)	8.5 s / 9.7 s	25.5 s / 37.7 s

Tabla 5. Pruebas en una laptop sin tarjeta NVIDIA, tomadas del archivo de métricas que guarda la aplicación.

La prueba 1 confirma que la separación funciona con voces nuevas y en otra computadora: transcribiendo la mezcla solo salía la frase de Dulce. La prueba 2 muestra el límite del modelo: con tres personas hablando a la vez durante casi toda la grabación, una de las dos pistas lleva dos voces revueltas, su huella no se parece a nadie y sale como "Desconocido"; solo 1 de las 3 partes encimadas pasó la revisión de que fueran dos personas distintas. Volver a procesarla en modo Mejorado tardó menos, pero dio casi lo mismo, porque Mejorado no separa voces.

Tiempos en la PC con tarjeta NVIDIA. Estas son tres de las grabaciones del video. En esa PC Whisper usa la tarjeta, pero las huellas y la separación se calcularon en el procesador (Intel Core i5-13600K), porque PyTorch quedó instalado en su versión para procesador.

Grabación (modo Completo)	Duración	Quién habla	Transcribir	Separar	Retraso en vivo (prom. / máx.)
Plática por turnos, 2 personas	75.5 s	44 s	39 s	3 min 11 s	3.7 / 6.2 s
Plática con partes encimadas	48.5 s	29 s	25 s	2 min 42 s	6.2 / 9.0 s
Dos personas a la vez todo el tiempo	11.7 s	8 s	6 s	2 min 32 s	4.3 / 6.1 s

Tabla 6. En la PC con tarjeta NVIDIA el retraso en vivo quedó entre 3.7 y 6.2 segundos en promedio, dentro de la meta de 10 s.

Rendimiento general. Identificar al hablante de una frase de 6 s tarda 2.5 s en un procesador de 2 núcleos (1.3 s en modo rápido, que la aplicación activa sola si se atrasa). Separar voces es lo más tardado, por eso solo se hace en la versión final, solo en las partes encimadas y con un tope del 30 % del audio.

Pruebas con conversaciones reales de la entrega anterior. Dos integrantes (Uriel y Alejandro) se enrolaron y grabaron tres conversaciones en una laptop sin tarjeta NVIDIA (Intel Core i5 de 13.ª generación, gráficos Intel Iris Xe), con el modelo chico de Whisper en el procesador. La prueba 3 siguió un guion de 2 min 41 s con turnos normales, respuestas cortas, una interrupción, una parte hablando al mismo tiempo, términos en inglés, números y turnos muy rápidos.

Medida (prueba 3, guion de 355 palabras)	En vivo	Versión final
Atribución de hablante (palabras bien reconocidas con la persona correcta)	98.6 %	98.6 %
Palabras del guion reconocidas correctamente	78.0 %	78.3 %
Error de palabras (WER)	30.1 %	28.7 %

Tabla 7. Medido con la versión 2.2 y el modelo chico también en la versión final. La referencia es el guion; el WER incluye como "palabras inventadas" algunas indicaciones del guion que se leyeron en voz alta.

De esas pruebas salieron varios de los cambios de la versión final: la versión final ahora usa el modelo grande también sin tarjeta NVIDIA, las frases en inglés ya se detectan, y la parte donde hablaron al mismo tiempo, en la que antes se perdía la frase de una persona, ahora se puede separar.

6. CONCLUSIONES

Se desarrolló un sistema que transcribe conversaciones en español con el nombre de quien habla, usando un solo micrófono y una computadora personal, sin internet y sin entrenar modelos propios. La versión final (4.0) funciona de principio a fin en una aplicación de escritorio y en un ejecutable para Windows, y se probó en tres computadoras distintas. Al acotar el problema a personas enroladas que se turnan para hablar, un problema abierto de investigación se convirtió en uno resoluble: el análisis mostró que era descomponible, incierto y secuencial, y la técnica que mejor lo resolvió fue combinar modelos preentrenados con una búsqueda del mejor camino (Viterbi) en un espacio de estados de hablantes, umbrales por persona y reglas sencillas. En la versión final se agregó un cuarto modelo preentrenado, MossFormer2, para el caso que antes solo se marcaba: dos personas hablando al mismo tiempo.

La meta de atribución se cumple tanto en conversaciones armadas (89.9 % a 98.7 % según el número de personas) como en la conversación real con guion (98.6 %, meta de 90 %). La meta de calidad del texto se cumple con el modelo grande (8.7 % de error, meta de 10 %). La meta de retraso en vivo se cumple en la PC con tarjeta NVIDIA (3.7 a 6.2 s en promedio) y en la laptop sin ella con dos personas (8.5 s), pero no con tres personas hablando a la vez. Con dos voces encimadas, separar recuperó 69 % de las palabras contra 32 % sin separar, y todas las pistas quedaron con su dueño.

Medida	Primera versión	Versión final
Palabras con el hablante correcto (conversaciones armadas)	84.6 %	97.4 %
Error de transcripción con términos en inglés	10.3 % a 22.8 %	8.7 %
Términos técnicos bien escritos	83 %	89 %
Palabras recuperadas con dos voces a la vez	32 %	69 %

Tabla 8. Cuánto mejoró el sistema respecto a la primera versión. El error de 10.3 % a 22.8 % es de la misma configuración en dos corridas distintas: sin bloques, Whisper no era estable.

Los cambios más útiles salieron de medir con datos propios: el umbral por persona resolvió que una persona sola apareciera como "Desconocido", transcribir por bloques cortados en pausas eliminó los bucles de Whisper, y revisar en qué se equivocaba el sistema en pláticas reales llevó a la opción de quitar personas de la plática y a la separación de voces encimadas. El sistema todavía se puede mejorar, sobre todo en velocidad sin tarjeta NVIDIA y en conversaciones con más de dos personas hablando a la vez.

6.1 Limitaciones

- Solo separa a dos personas a la vez. Con tres o más voces encimadas, una pista queda revuelta y sale como "Desconocido" (prueba 2 de la sección 5.6).
- Sin tarjeta NVIDIA, el modo Completo es lento: en una laptop tardó unas 19 veces lo que dura el audio. El modo Mejorado tarda mucho menos, pero no separa voces.
- Hay que enrolar a todos los que van a hablar: una persona no registrada con voz parecida a una registrada puede salir con el nombre de esa persona; solo se reconoce como desconocida alrededor del 67 % de las veces.
- Las voces muy parecidas entre sí se confunden más, sobre todo en plática real, donde el parecido con la propia huella baja.
- Las respuestas de una sola palabra ("ajá", "va") a veces se pierden, y en turnos muy rápidos se pueden asignar a la otra persona.
- Los parámetros de los perfiles de entorno se ajustaron con las grabaciones del equipo; falta probarlos en más salones y lugares con ruido.

6.2 Lo que se hizo de los siguientes pasos de la entrega anterior

Paso propuesto el 6 de noviembre	Estado en la versión final
Probar en entornos más variados	Se probó en tres computadoras y con voces nuevas; faltan salones con ruido de fondo.
Usar el modelo grande en la pasada final sin tarjeta NVIDIA	Hecho: la versión final usa large-v3-turbo también en el procesador.
Ajustar los parámetros según el entorno	Hecho: perfiles de cuarto silencioso, salón de clase y exterior (Tabla 1).
Comparar las voces enroladas entre sí	Hecho: tabla de parecido entre voces, métricas por persona y "Probar voz".

Paso propuesto el 6 de noviembre	Estado en la versión final
Opción para traducir o no el inglés	Hecho: detección de frases en inglés y traducción opcional.
Mejorar el diseño de la interfaz	Hecho: interfaz nueva con CustomTkinter.
Revisar los comentarios del código y el manual (LEEME)	Hecho: comentarios en español, sencillos, y carpeta del proyecto ordenada.
Separar voces encimadas (trabajo futuro)	Hecho para dos voces con MossFormer2.

6.3 Trabajo futuro

- Hacer más rápida la separación en computadoras sin tarjeta NVIDIA (por ejemplo, usando la gráfica integrada o un separador más ligero), para poder usar el modo Completo en cualquier laptop.
- Separar a más de dos personas a la vez con un modelo que maneje tres voces.
- Mejorar el reconocimiento de personas no registradas con voz parecida a una registrada.
- Probar en salones reales con ruido de fondo y más personas, y ajustar los perfiles de entorno con esos datos.

ANEXOS

Anexo A. Lenguaje, herramientas, versiones y enlaces

Elemento	Versión / detalle
Lenguaje	Python 3.11.9
Sistema operativo	Windows 11 (versión 10.0.26200), 64 bits
Interfaz gráfica (nuevo)	CustomTkinter 6.0.0 (con darkdetect 0.8.0), sobre tkinter (Tcl/Tk 8.6)
Imágenes de la interfaz (nuevo)	Pillow 13.0.0
PyTorch / torchaudio	2.14.1 / 2.11.0
SpeechBrain	1.1.2 (modelo speechbrain/spkrec-ecapa-voxceleb)
silero-vad	6.2.3 (detector de voz Silero VAD)
faster-whisper / CTranslate2	1.2.1 / 4.8.3 (modelos large-v3-turbo y small)
Separación de voces (nuevo)	MossFormer2_SS_16K (ClearerVoice-Studio); usa einops 0.8.2 y rotary-embedding-torch 0.9.2
Traducción opcional (nuevo)	Marian opus-mt-en-es con transformers 5.22.2, sentencepiece 0.2.2 y CTranslate2
NumPy / SciPy	2.4.6 / 1.17.1
sounddevice / soundfile	0.5.6 / 0.14.0
PyAV / onnxruntime	18.1.0 / 1.31.0
huggingface_hub	2.2.0
CUDA (para la tarjeta NVIDIA)	nvidia-cublas-cu12 12.9.2.10, nvidia-cudnn-cu12 9.27.0.42
Ejecutable	PyInstaller 6.22.3 con pyinstaller-hooks-contrib 2026.9
Editor	Visual Studio Code
Control de versiones	Git y GitHub (github.com/UJefte/transcriptor-multihablante)

Enlaces oficiales de las librerías, modelos y datos usados:

Elemento	Enlace
Repositorio del proyecto	https://github.com/UJefte/transcriptor-multihablante
Python	https://www.python.org
CustomTkinter	https://customtkinter.tomschimansky.com
Pillow	https://python-pillow.org
PyTorch y torchaudio	https://pytorch.org
SpeechBrain	https://speechbrain.github.io
Modelo de huella de voz ECAPA-TDNN	https://huggingface.co/speechbrain/spkrec-ecapa-voxceleb
Datos de entrenamiento de ECAPA (VoxCeleb)	https://www.robots.ox.ac.uk/~vgg/data/voxceleb/
Silero VAD (detector de voz)	https://github.com/snakers4/silero-vad
Whisper (OpenAI)	https://github.com/openai/whisper
faster-whisper	https://github.com/SYSTRAN/faster-whisper
CTranslate2	https://github.com/OpenNMT/CTranslate2
Modelo Whisper large-v3-turbo	https://huggingface.co/mobiuslabsgmbh/faster-whisper-large-v3-turbo
Modelo Whisper small	https://huggingface.co/Systran/faster-whisper-small
ClearerVoice-Studio (código de MossFormer2)	https://github.com/modelscope/ClearerVoice-Studio
Modelo MossFormer2_SS_16K	https://huggingface.co/alibabasglab/MossFormer2_SS_16K
einops	https://github.com/arogozhnikov/einops
rotary-embedding-torch	https://github.com/lucidrains/rotary-embedding-torch
Modelo de traducción opus-mt-en-es	https://huggingface.co/Helsinki-NLP/opus-mt-en-es
transformers	https://github.com/huggingface/transformers
sentencepiece	https://github.com/google/sentencepiece
sounddevice	https://python-sounddevice.readthedocs.io
soundfile	https://python-soundfile.readthedocs.io
NumPy / SciPy	https://numpy.org · https://scipy.org
PyAV	https://github.com/PyAV-Org/PyAV
ONNX Runtime	https://onnxruntime.ai
huggingface_hub	https://github.com/huggingface/huggingface_hub
PyInstaller	https://pyinstaller.org
Librerías CUDA de NVIDIA (cuBLAS y cuDNN)	https://pypi.org/project/nvidia-cublas-cu12/ · https://pypi.org/project/nvidia-cudnn-cu12/

Anexo B. Experimento de términos técnicos en inglés

Configuraciones del reconocedor de voz comparadas sobre la misma lectura (modelo grande en tarjeta NVIDIA):

Configuración	Error	Palabras inventadas	Términos bien escritos
A. Sin ayuda de vocabulario	10.3 %	17	83 %
B. Vocabulario + arrastre del texto anterior	24.9 %	59	80 %
C. Vocabulario sin arrastre + correcciones	10.0 %	13	89 %
E. Vocabulario + penalización de repeticiones	33.1 %	118	84 %
H. Vocabulario por bloques cortados en pausas (elegida)	8.7 %	15	89 %

Tabla 9. La configuración C no tenía bucles pero perdía la puntuación después de los primeros 30 s; H la conserva (34 puntos contra 33 de la referencia).

Anexo C. Uso del ejecutable

1. Copiar la carpeta Transcriptor completa y abrir Transcriptor.exe.
2. Esperar a que el indicador de modelos se ponga verde.
3. En Personas, "Enrolar persona" y registrar a cada participante (10 tomas, unos 4 minutos por persona), en la misma laptop y a la distancia de la mesa donde se va a grabar.
4. En Ajustes, elegir el entorno y el modo al terminar de grabar (Rápido, Mejorado o Completo).
5. En Conversación, tocar los nombres de quienes no están en la plática, presionar "Grabar" y, al terminar, "Terminar y mejorar texto".
6. "Guardar" exporta la transcripción; la versión final y las métricas también se guardan solas.

Las voces registradas se guardan en la carpeta de datos de cada usuario de Windows (%LOCALAPPDATA%\TranscriptorMultihablante), no en la carpeta del programa, para que al compartir el ejecutable no se compartan los enrolamientos de nadie. El paquete de pruebas que se crea en Ajustes tampoco incluye voces.

Anexo D. Referencias

Chondhekar, S. et al. (2025). When De-noising Hurts: A Systematic Study of Speech Enhancement Effects on Modern Medical ASR Systems. arXiv:2512.17562.

Desplanques, B., Thienpondt, J. y Demuynck, K. (2020). ECAPA-TDNN: Emphasized Channel Attention, Propagation and Aggregation in TDNN Based Speaker Verification. Proc. Interspeech 2020, 3830-3834.

González Pérez, P. P. (s. f.). Inteligencia Artificial: problemas y búsqueda [Notas de clase].

Lanzendörfer, L. et al. (2025). Benchmarking Diarization Models. arXiv:2509.26177.

Nagrani, A., Chung, J. S. y Zisserman, A. (2017). VoxCeleb: A Large-Scale Speaker Identification Dataset. Proc. Interspeech 2017.

Rabiner, L. R. (1989). A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition. Proceedings of the IEEE, 77(2), 257-286.

Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C. y Sutskever, I. (2023). Robust Speech Recognition via Large-Scale Weak Supervision. Proc. ICML 2023.

Ravanelli, M. et al. (2021). SpeechBrain: A General-Purpose Speech Toolkit. arXiv:2106.04624.

Rich, E. y Knight, K. (1994). Inteligencia Artificial (2.ª ed.). McGraw-Hill.

Silero Team (2024). Silero VAD: pre-trained enterprise-grade Voice Activity Detector. GitHub: snakers4/silero-vad.

Subakan, C., Ravanelli, M., Cornell, S., Bronzi, M. y Zhong, J. (2021). Attention Is All You Need in Speech Separation. Proc. ICASSP 2021.

SYSTRAN (2023). faster-whisper: Faster Whisper transcription with CTranslate2. GitHub: SYSTRAN/faster-whisper.

Tiedemann, J. y Thottingal, S. (2020). OPUS-MT: Building open translation services for the World. Proc. EAMT 2020, 479-480.

Vinnikov, A. et al. (2024). NOTSOFAR-1 Challenge: New Datasets, Baseline, and Tasks for Distant Meeting Transcription. Proc. Interspeech 2024.

Viterbi, A. J. (1967). Error Bounds for Convolutional Codes and an Asymptotically Optimum Decoding Algorithm. IEEE Transactions on Information Theory, 13(2), 260-269.

Zhao, S., Ma, Y., Ni, C., Zhang, C., Wang, H., Nguyen, T. H., Zhou, K., Yip, J. Q., Ng, D. y Ma, B. (2024). MossFormer2: Combining Transformer and RNN-Free Recurrent Network for Enhanced Time-Domain Monaural Speech Separation. Proc. ICASSP 2024.