Transcriptor multihablante en español

Avance del proyecto y guía de pruebas para el equipo · Proyecto final de Inteligencia Artificial · FES Aragón, UNAM · 17 de octubre de 2026

1. Qué hace y estado del avance

El programa escucha una conversación por el micrófono, identifica quién habla entre las personas registradas (enroladas) y escribe la transcripción en un archivo TXT casi al momento, con unos 2 segundos de retraso:

```
[Uriel] (00:03 - 00:09): Bueno, yo estoy aquí hablando ahorita solito...
[Mama] (00:47 - 00:52): Pues solamente mandar para el regalo del bebé.
[Desconocido] (00:29 - 00:29): Sí, sí.
```

Cómo funciona: un detector de voz (Silero VAD) corta el audio en frases. Cada 2 segundos se compara la huella de voz (modelo ECAPA de SpeechBrain) contra las voces enroladas. Whisper transcribe la frase en español y cada palabra se asigna a quien hablaba en ese momento. Quien no está enrolado sale como *Desconocido*. No se entrena ningún modelo: se usan modelos preentrenados y se integran.

Resultados de la primera prueba real (2 personas, micrófono de diadema, 1 minuto):

Medida	Resultado
Latencia (fin de frase hasta texto)	Mediana 1.7 s, máxima 3.3 s
Similitud de cada voz consigo misma	0.77 típica (0.66 la más baja)
Similitud entre las dos voces	0.17 típica (0.24 la más alta)
Identificación del hablante	Correcta en todas las frases largas; fallaron 3 fragmentos de 1 s o menos
Transcripción	Casi perfecta con voz clara; más errores con audio de bocina o voces encimadas

Repositorio: https://github.com/UJefte/transcriptor-multihablante

2. Requisitos

- Windows (también funciona en Mac o Linux), micrófono e internet la primera vez (descarga unos 600 MB de modelos).
- **Python 3.11.9.** No usar 3.13 ni 3.14: algunas librerías no los soportan todavía. Se instala junto al Python que ya tengas, sin borrar nada.
- Git. No hace falta tarjeta gráfica (GPU).

3. Instalación (una sola vez)

a) Descargar e instalar Python 3.11.9. En la primera pantalla **no** marcar "Add python.exe to PATH" y dar clic en *Install Now*. Al final, dar clic en *Disable path length limit*:

```
https://www.python.org/ftp/python/3.11.9/python-3.11.9-amd64.exe
```

b) Abrir una terminal (escribir `cmd` en la barra de direcciones del Explorador, dentro de la carpeta donde quieras el proyecto) y correr uno por uno:

```
git clone https://github.com/UJefte/transcriptor-multihablante.git
cd transcriptor-multihablante
py -3.11 -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt
```

La instalación tarda de 5 a 15 minutos. Debe terminar con *Successfully installed ...*. Cada vez que abras una terminal nueva, entra a la carpeta y activa el entorno con `.venv\Scripts\activate` (aparece `(.venv)` al inicio de la línea).

4. Comandos

Para qué	Comando
Probar que el micrófono sí capta sonido	`python probar_microfono.py`
Ver la lista de micrófonos	`python transcriptor.py dispositivos`
Enrolar a una persona (40 s)	`python transcriptor.py enrolar --nombre Ana`
Recalcular voces tras borrar o renombrar carpetas	`python transcriptor.py galeria`
Transcribir en vivo (Ctrl+C para terminar)	`python transcriptor.py vivo --detalle`
Usar un umbral distinto	`python transcriptor.py vivo --detalle --umbral 0.38`
Procesar un audio ya grabado	`python transcriptor.py archivo pruebas\P01.wav`
Comparar contra la transcripción manual	`python evaluar.py referencias\P01.txt transcripciones\P01_....txt --etiqueta "small"`

Todo se guarda en la carpeta `transcripciones`: el TXT y el audio WAV de cada sesión. Para abrirla: `start transcripciones`.

5. Cómo hacer las pruebas con gente de tu entorno

Antes de grabar, pide permiso a cada persona y explícale que su voz solo se usa para el proyecto. Las grabaciones se quedan en tu computadora: el repositorio está configurado para **no** subir voces ni audios.

Paso 1. Revisa el micrófono. Corre `python probar_microfono.py`. Si dice SILENCIO, el micrófono está silenciado (revisa el botón de mute de los audífonos) o es otro dispositivo.

Paso 2. Enrola a 2 o 3 personas, cada una con su nombre. Usen el mismo micrófono y la misma distancia que en la prueba, y graben en un lugar callado. Cada quien lee el párrafo que muestra el programa y luego habla libre hasta completar 40 segundos. **Solo habla la persona que se está enrolando**: si tú lees por otra persona, el sistema guarda tu voz con su nombre.

Paso 3. Revisa la calibración. Al enrolar se muestran las similitudes y un umbral sugerido. Lo ideal es una similitud propia arriba de 0.6 y una similitud con voces ajenas abajo de 0.3. Si aparece el aviso "suenan muy parecido", vuelve a enrolar a esas personas con más audio.

Paso 4. Prueba en vivo con `vivo --detalle`. Espera el aviso ESCUCHANDO y revisa que el medidor se mueva al hablar. Hagan estas situaciones (unos 2 minutos cada una):

Prueba	Situación
P01	2 personas enroladas hablando por turnos claros
P02	3 personas enroladas por turnos
P03	3 personas con interrupciones cortas a propósito
P04	2 enroladas + 1 persona NO enrolada (debe salir como Desconocido)
P05	Con ruido de fondo (tele, calle, cocina)

Si una persona enrolada sale como Desconocido con similitud entre 0.35 y el umbral, repite con `--umbral 0.38`. Si dos personas se confunden, sube el umbral o enrólalas con más audio.

6. Qué reportar al equipo

- El texto de la calibración al enrolar (las líneas de similitud y el umbral sugerido).
- El TXT de cada prueba y el resumen de latencia que aparece al terminar.
- Quién habló realmente en cada parte, para poder comparar.
- Qué falló: frases mal transcritas, hablantes confundidos y en qué situación.
- No subir audios a GitHub. Si hace falta compartir uno, por Drive y solo con permiso de quien sale en él.

7. Problemas comunes

Problema	Solución
probar_microfono dice SILENCIO	Quitar el mute del micrófono o elegir otro con --dispositivo N (ver 'dispositivos')
Error al instalar librerías	Revisar que el entorno se creó con py -3.11 y no con Python 3.13 o 3.14
Avisos de 'symlinks' o 'HF_TOKEN'	Son normales, se pueden ignorar
Va muy atrasado	Usar --modelo base (más rápido, menos preciso)
Muchas palabras mal transcritas	Hablar más cerca del micrófono; probar --modelo medium si la computadora aguanta
Pone Desconocido a alguien enrolado	Bajar --umbral (0.35-0.40) o enrolar más audio
Corta las frases a la mitad	--silencio-ms 700